

# Práctica 1

*Control de calidad de piezas de carne*

**Antonio J. Cabrera**

**Paul Gazel-Anthoine**

Visión por Computador  
Primavera 2018-19

## INTRODUCCIÓN

Esta práctica consiste en implementar técnicas de detección de umbral en imágenes en escala de grises utilizando MATLAB. El objetivo es medir el porcentaje de grasa de unas piezas de carne a partir de fotografías. Para ello debemos aislar la pieza de carne del resto de la imagen y posteriormente aplicar diferentes algoritmos para binarizar la pieza de carne: por un lado la grasa y por el otro la parte magra.

## APLICACIÓN

1. Binarización de la imagen para detectar la pieza de carne y poner a cero el resto de la imagen.
2. Salida del histograma de la pieza de carne.
3. Binarización de la pieza de carne en parte magra y parte grasa mediante llamadas a diferentes funciones que implementan técnicas de *thresholding*.
4. Salida de tabla resumen con los porcentajes de grasa obtenidos para cada pieza de carne con cada técnica implementada.

Los métodos implementados son: binarización con umbral personalizable por el usuario, binarización con umbral automático mediante función `graythresh`, método Niblack y método Ridler.

**\* Antes de cargar las imágenes en la aplicación hemos recortado manualmente la parte de interés de la fotografía.**

## MÉTODO NIBLACK GLOBAL

Este método utiliza la mediana y desviación estándar del nivel de gris de los píxeles vecinos de cada píxel para obtener el umbral ( $U$ ). Cada píxel pertenece a la región grasa o magra en función de si su valor es superior a  $U$  o no, respectivamente.

Niblack normalmente analiza los píxeles vecinos con una ventana (por ejemplo 15x15). Hemos comprobado que funciona muy bien para binarizar otro tipo de imágenes (como puede ser un periódico antiguo). Sin embargo, en este caso era demasiado sensible a la iluminación y cuanto más grande hacíamos la ventana, mejor funcionaba. El mejor resultado ha sido usar el tamaño total de la imagen como ventana, es decir, utilizar la mediana y desviación estándar de la pieza de carne.

## MÉTODO RIDLER

Este método, de enfoque global e iterativo, parte de una aproximación del umbral y dividiendo la imagen en región de fondo y de objeto.

A continuación, de forma iterativa y hasta que la diferencia entre el umbral obtenido  $U_n$  y el calculado en la iteración previa  $U_{n-1}$  sea inferior a un determinado margen de error ( $\varepsilon$ ), se obtiene  $U_{n+1}$  haciendo el promedio de las medianas de la región de fondo y de objeto formadas por el umbral  $U_n$ .

$$U_{n+1} = \frac{\text{mediana}(\text{imagen} \leq U_n)}{2} + \frac{\text{mediana}(\text{imagen} > U_n)}{2}$$

## RESULTADOS

Junto a este informe, adjuntamos dos archivos PDF, uno con una salida extensa de imágenes y realces para valorar los resultados y otro más breve con la salida especificada en el enunciado.

	TH User	TH Auto	TH Niblack	TH Ridler
1	28.52%	32.86%	32.86%	33.39%
2	35.76%	29.08%	31.13%	31.97%
3	30.23%	34.11%	33.97%	34.11%
4	32.60%	27.69%	30.50%	32.60%
5	31.17%	33.31%	33.31%	34.81%
6	26.66%	29.10%	31.62%	32.83%
7	23.43%	28.71%	30.90%	33.30%
8	23.75%	27.61%	31.43%	32.18%
9	28.74%	31.10%	31.73%	33.77%
10	24.71%	26.20%	29.97%	30.25%
11	26.80%	28.63%	30.09%	32.18%
12	34.12%	35.29%	34.96%	36.59%
13	33.19%	35.08%	33.49%	33.49%
14	39.36%	38.15%	36.31%	36.69%

Tabla 1: Porcentajes de grasa para cada imagen en función de la técnica de binarización utilizada

Como podemos observar en la tabla 1, los porcentajes obtenidos son bastante coherentes entre sí. La técnica automática y la personalizada por el usuario han ofrecido más variabilidad para diferentes imágenes, con valores del 23-40%, mientras que los dos métodos que hemos implementado han sido más estables en unos porcentajes alrededor del 30-34%.

## CONCLUSIONES

Tras probar varios métodos de binarización, algunos con mejor resultado y otros totalmente inutilizables para las imágenes que hemos tratado, hemos podido extraer algunas conclusiones. En primer lugar, como suele ser habitual en técnicas de visión por computador, la efectividad de la técnica variará mucho según las condiciones de la imagen a analizar; por ejemplo, hemos implementado el método Sauvola, pero no ha sido de utilidad para estudiar estas imágenes por la distribución que tiene la grasa en la carne, mientras que hemos probado el resultado con imágenes de documentos antiguos y funcionaba de maravilla.

Finalmente, en los métodos que hemos observado, hemos visto que hay un importante trabajo de personalización del algoritmo según el tipo de imágenes a analizar. Por ejemplo, Ridler converge iterando sobre un umbral inicial aproximado que hemos decidido que sea un 5% superior a la mediana, para que parta de algún punto cercano al óptimo respecto al histograma (Figura 1). Por otro lado, Niblack utiliza un umbral ( $U$ ) que es calculado con la función de la mediana ( $\mu$ ) y la desviación estándar ( $\sigma$ ):

$$U = \mu - k * \sigma$$

Esta  $k$  es un factor que debemos determinar y va a ser muy importante para obtener resultados razonables.




Figura 1: Umbral aproximado de inicio (Ridler)